以邏輯迴歸操作「作者邊界」：《紅樓夢》前八十回與後四十回

《紅樓夢》前八十回與後四十回的作者歸屬，是紅學中長期未決、且直接影響後四十回評價的問題。本文以段落為單位，以邏輯迴歸區分兩段文本，並將模型用於作者存疑的第六十七回。研究限於詞彙層面的文體可分性，不涉及著作權考證。

一、標籤與問題

本文的標籤是歷史切分，不是作者鑑定。標籤按通行一百二十回本劃分：一至八十回為曹雪芹（0），八十一至一百二十回為高鶚（1）。此為以回為單位的粗略標籤，預設一回僅一位作者。胡適以來的「曹著高續」說屬歷史與文獻判斷，不能充當分類器標準答案；通行說法認為後四十回經程偉元、高鶚整理，未必出自一人之手。本文因此將標籤視為兩個歷史文本群體，而非兩位作者的證明。0.88僅能說明兩段文本可分，不能說明著作權歸屬。

方法上，分類器與主題模型不同：前者需要標籤，學到的是類別邊界；後者依靠共現聚類，不需標籤。文體計量學提示，作者習慣常存於虛詞。本文採用邏輯迴歸，因為係數可讀，便於觀察哪些詞將兩類分開。

二、語料、清洗與切分

語料以段落為單位，按回切分。文本單位為一百至四百六十字的連續段落，僅在句末斷開，共四千九百六十段（曹三千三百五十、高一千六百一十）；第六十七回整回留出，共五十五段，不參與訓練與測試。

常見分詞問題在於「人名+說話動詞」被切為一詞。舊版四千九百六十段中，「賈政道」「黛玉笑」一類連寫共一千二百七十四處、四十七種；「賈政道」曾獲0.62正權重，成為高鶚側特徵。模型學到的更接近說話人信息，難以視為寫作風格。本次先將人名與後續「道、笑、說、問、答、哭、罵、叫、嚷、嘆、念、想」分離，再交jieba分詞；同樣處理後，殘留為零。此改動未增數據，僅還原連寫單位。其代價為準確率自0.89降至0.88：四段改變預測，三段由對變錯、一段由錯變對，合計少了兩段。舊版準確率中有一部分來自此類說話標籤。

其餘清洗只涉及格式，不涉及詩詞。按回目切分，標題行不計入正文；重複回目標題跳過；第一回之前的目錄、題記不納入語料。詩詞、對聯與判詞仍保留於段落之中，未強行刪除，因其刪除將改變段落邊界與標籤分佈；其代價為詩詞用詞仍進入特徵，留待後續處理。

切分按回進行，避免同回段落同時進入訓練與測試：每類隨機取八成回目訓練、兩成測試，種子42；訓練覆蓋六十三與三十二個回目，測試十六與八個；再各抽四百與一百段，兩類均為四百對四百、一百對一百。

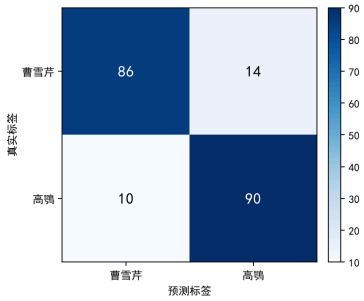
三、特徵、模型與結果

特徵為詞一元與二元TF-IDF，分詞用jieba，僅在訓練集擬合，共五千四百八十五維。TF-IDF按詞頻與逆文檔頻率加權，並按段落長度標準化：長段不因字多而佔優勢，常見詞的出現次數也被壓低；較原始詞頻更適合長短不一的段落。分類器為邏輯迴歸，liblinear，C取一。

測試結果為0.88，兩類表現接近：二百段中176段判對。混淆矩陣 [[86,14],[10,90]]：曹雪芹十四段誤判為高鶚，高鶚十段誤判為曹雪芹。高鶚精確率0.865、召回率0.900；曹雪芹0.896、0.860。F1為兩者的調和平均（2PR/(P+R)），高鶚0.882、曹雪芹0.878。兩側接近；全判一類僅0.50。

模型確實學到部分詞彙風格，但仍未擺脫專名。權重最高的特徵大體支持文體解釋：曹雪芹一側為笑、笑道、忙、與、皆、一面，高鶚一側為沒有、麼、聽見、的話、叫、所以、就是、呢。此類詞多與情節無關；然而賈政、紫鵑等人名仍以內容詞進入正權重。

二十四個錯誤幾乎都靠近分界，且集中於對話、過渡與詩詞。誤判為高鶚的曹雪芹段落，概率多在0.50–0.68；反過來多在0.38–0.49，多數仍靠近0.5。第十四回昭兒報喪一段，舊版0.497判對，清洗後0.517判高；第二十八、六十九回各有一段同理。此類錯判多因證據不足，分數越過0.5或落到0.5以下。該段對話短、套話多，句子受人物口吻影響；詩詞用詞又與散文相差較遠。內容詞仍有影響：人物、器物與場景隨題材變化。



四、第六十七回

第六十七回略微偏向高鶚，但不足以定案。模型用於留出的這一回：五十五段中四十四段判高鶚、十一段判曹雪芹；平均P(高鶚) 為0.571，中位數0.574，最低0.376，最高0.802。測試集曹雪芹平均0.40、高鶚0.62。按段落統計為44比11，多數在高鶚一側；均值僅高於0.5約0.07，多數並不等於確信。門檻提高到0.6，判高鶚者由四十四段降至二十一段，結論對門檻敏感。

這一回在紅學中本就有疑問，模型結果只能與之呼應，不能作證。此回寫薛蟠帶回土產、黛玉見物思鄉，亦寫鳳姐訊問家童，情節承接前後，語言則在對話與敘述之間來回。模型將其推向高鶚，卻未形成把握：既不像典型曹雪芹，亦不完全像後四十回。單回五十五段過少，且該回在庚辰本等部分早期抄本中缺失，現存文本可能經過拼合與補寫；分類器只能說明，該回用詞與前八十回的平均特徵不同。

五、討論與侷限

結果不能完全讀作「機器證明後四十回非曹雪芹所作」。模型學到的，是「前八十回/後四十回」這一歷史切分的邊界；標籤先於模型存在，準確率再高，亦僅為該邊界在詞彙層面的痕跡。若後四十回經過整理、潤色與補寫，模型捕捉到的，可能是版本與整理層次的差異，而非兩位作者的筆跡。0.88能證明的，只是兩段文本在詞彙上可分；不能據此判定著作權。

清洗使準確率略降，卻使結果更可解釋。舊版0.89中有一部分來自「賈政道」一類說話標籤：這類標籤同時包含人物與敘述位置的信息，使模型在分界附近多判對三段。拆分之後，準確率略降，可解釋性略增；0.88與0.89的差距，亦落在二百段測試的抽樣誤差之內。

本實驗的侷限可歸為四層。標籤最為粗略：以回為單位，預設一回僅一位作者，忽略回內混合與後人修改。特徵仍含大量內容詞，模型可能依靠情節與專名取勝。概率未經校正，0.5附近的分數被壓在一起，靠近分界的樣本更容易改變預測。切分僅做一次，訓練僅覆蓋六十三與三十二個回目，二百段測試的95% 置信區間約為正負4.5個百分點。後續工作可先按回做交叉驗證；以高鶚其他作品作外部驗證；將人名與說話動詞的清洗推廣至更多稱呼；並逐段細讀錯判的段落。

分類器能指出的，是文本在何處分開；不能代替研究者判斷。0.88表明文體信號確實存在，第六十七回0.571則提示：統計證據僅能支持「可疑」，不能替代版本與文獻的考證。數字方法的作用，是把原本只能憑感覺的閱讀印象，變成可核對、可討論的數字；至於結論，仍須回到文本。

AI使用聲明：數據處理、模型代碼在AI工具豆包協助下完成；研究設計、報告文字定稿與結果核對由作者負責。